

Demografik Veri Analizi

Bu uygulamada Pandas kütüphanesini kullanarak veri analizi yapacağız. Aşağıda 1994 Census veri tabanından çıkarılan bir demografik veri seti verilmiştir.

index	age	workclass	fnlwgt	education	education-num	marital-status	occupation	relationship	race	sex	capital-gain	capital-loss	hours-per-week	native-country	salary
0	39	State-gov	77516	Bachelors	13	Never-married	Adm-clerical	Not-in-family	White	Male	2174	0	40	United-States	<=50K
1	50	Self-emp-not-inc	83311	Bachelors	13	Married-civ-spouse	Exec-managerial	Husband	White	Male	0	0	13	United-States	<=50K
2	38	Private	215646	HS-grad	9	Divorced	Handlers-cleaners	Not-in-family	White	Male	0	0	40	United-States	<=50K
3	53	Private	234721	11th	7	Married-civ-spouse	Handlers-cleaners	Husband	Black	Male	0	0	40	United-States	<=50K
4	28	Private	338409	Bachelors	13	Married-civ-spouse	Prof-specialty	Wife	Black	Female	0	0	40	Cuba	<=50K
5	37	Private	284582	Masters	14	Married-civ-spouse	Exec-managerial	Wife	White	Female	0	0	40	United-States	<=50K
6	49	Private	160187	9th	5	Married-spouse-absent	Other-service	Not-in-family	Black	Female	0	0	16	Jamaica	<=50K
7	52	Self-emp-not-inc	209642	HS-grad	9	Married-civ-spouse	Exec-managerial	Husband	White	Male	0	0	45	United-States	>50K
8	31	Private	45781	Masters	14	Never-married	Prof-specialty	Not-in-family	White	Female	14084	0	50	United-States	>50K
9	42	Private	159449	Bachelors	13	Married-civ-spouse	Exec-managerial	Husband	White	Male	5178	0	40	United-States	>50K

Show 10 per page

1 2 10 100 1000 1900 1990 2000

Aşağıdaki soruları Pandas kütüphanesini kullanarak yanıtlayınız.

- Bu veri setinde hangi ırktan kaç kişi vardır? Her ırkın sayıyı gözükmelidir.
- Erkeklerin yaş ortalaması nedir?
- Lisans derecesine sahip kişilerin yüzdesi nedir?
- Lisans, Yüksek Lisans veya Doktora yapanlar arasından yüzde kaç 50.000'den fazla kazanıyor?
- Lisans, Yüksek Lisans veya Doktora yapmayanlar arasından yüzde kaç 50.000'den fazla kazanıyor?
- Bir kişinin haftada çalıştığı minimum saat sayısı nedir?
- Haftada asgari saat çalışan insanların yüzde kaçının maaşı 50 binden fazladır?
- 50 binden fazla kazanan en yüksek yüzdeye sahip ülke hangisidir ve bu yüzde nedir?
- Hindistan'da 50 binden fazla kazananlar için en popüler meslek nedir?

Çözüm:

İlk olarak Pandas kütüphanemizi import ediyoruz.

```
import pandas as pd
```

Mevcut veri setini okuyarak data adlı değişkene atayalım. Böylece hesaplamalarımızı data değişkeninde kolayca yapabileceğiz.

```
data = pd.read_csv("../adult.data.csv") #... yerine veri setinin dosya konumunu yazmalısınız.
```

Veri setindeki ırk sayısını hesaplamak için `value_counts()` fonksiyonunu kullanacağız. Bu fonksiyon kategorik verileri saymamızı sağlar.

```
race_count = data['race'].value_counts()
output:
White                27816
Black                3124
Asian-Pac-Islander   1039
Amer-Indian-Eskimo    311
Other                 271
Name: race, dtype: int64
```

`mean()` fonksiyonu istenen sütunların ortalamasını döndürür. Bizden erkeklerin yaş ortalaması isteniyor. Cinsiyet kontrolü yapmak için `loc` fonksiyonundan yararlanacağız. `loc` satırlardaki ve sütunlardaki belirli değerlere erişmemizi sağlar. Nasıl mı? Örneğe bakalım :)

```
men = data.loc[ data['sex']=="Male"]
```

output:

	age	workclass	fnlwgt	education	education-num	marital-status	occupation	relationship	race	sex	capital-gain	capital-loss	hours-per-week	native-country	salary
0	39	State-gov	77516	Bachelors	13	Never-married	Adm-clerical	Not-in-family	White	Male	2174	0	40	United-States	<=50K
1	50	Self-emp-not-inc	83311	Bachelors	13	Married-civ-spouse	Exec-managerial	Husband	White	Male	0	0	13	United-States	<=50K
2	38	Private	215646	HS-grad	9	Divorced	Handlers-cleaners	Not-in-family	White	Male	0	0	40	United-States	<=50K
3	53	Private	234721	11th	7	Married-civ-spouse	Handlers-cleaners	Husband	Black	Male	0	0	40	United-States	<=50K

men değişkeninde sadece cinsiyeti erkek olanları verileri mevcuttur. Her satırı kontrol ederek *sex* sütununda *Male*'e sahip olanları değişkene ekliyor. Erkeklerin sadece yaş verisini görmek için:

```
age_men = data.loc[ data['sex']=="Male", 'age']
```

output:

```
0      39
1      50
2      38
3      53
7      52
      ..
32553  32
```

Artık `mean()` fonksiyonunu çağırarak erkeklerin yaş ortalamasını hesaplayabiliriz.

```
average_age_men = data.loc[ data['sex']=="Male", 'age'].mean()
```

output:

```
39.43354749885268
```

***Ekstra** Hem kadınların hem erkeklerin yaş ortalaması hesaplamak istiyorsak cinsiyete göre gruplama yaptığımızda yaş ortalamalarını hesaplayabiliriz.

```
average_age = data[["sex", "age"]].groupby("sex").mean()
```

output:

age	
sex	
Female	36.858230
Male	39.433547

Yukarıda ırkların sayısını hesapladığımız gibi eğitim derecelerinin sayılarını da hesaplayalım.

```
percentage_bachelors_count = data['education'].value_counts()
```

output:

```
HS-grad      10501
Some-college   7291
Bachelors     5355
Masters       1723
Assoc-voc     1382
11th          1175
Assoc-acdm    1067
10th          933
```

```
7th-8th          646
Prof-school      576
9th              514
12th             433
Doctorate        413
5th-6th          333
1st-4th          168
Preschool        51
Name: education, dtype: int64
```

Hangi eğitim düzeyinde kaç kişinin olduğunu görebiliyoruz. Lisans derecesine sahip kişilerin oranlarını hesaplamak için tüm sayısı lisans öğrenci sayısına böleceğiz. Sadece sayı bize gerektiği için *len* fonksiyonu ile elde edebiliriz. Yüzdesel olarak görmek için bölünen oranı 100 ile çarpıyoruz.

```
bachelors_count = len( data.loc[ data["education"] == "Bachelors"].value_counts() )
education_count = len(data['education'])
percentage_bachelors = (bachelors_count / education_count) * 100
print(percentage_bachelors)
output:
16.43991277909155
```

loc fonksiyonu ile sadece belirli değerler erişebilmiştik. Örneğin *"Male"* veya *"Bachelors"* gibi. Peki hem lisans hem de yüksek lisans öğrencilerine erişmek istiyorsak ne yapmalıyız? Yine aynı yöntem :) Bulmak istediğimiz değerleri bir liste olarak tutuyoruz.

```
array_higher_edu = ["Bachelors", "Masters", "Doctorate" ]
```

Şimdi *loc* fonksiyonu tüm satırlara bakacak. Diyeceğiz ki *isin* fonksiyonunu kullanarak sana liste olarak verdiğimiz değerlerden hangisi mevcut kontrol et. *isin* DataFrame'deki her öğenin değerleri içerilip içerilmediğine bakar.

```
array_higher_edu = ["Bachelors", "Masters", "Doctorate" ]
higher_education = data.loc[data["education"].isin(array_higher_edu)]
output:
```

	age	workclass	fnlwgt	education	education-num	marital-status	occupation	relationship	race	sex	capital-gain	capital-loss	hours-per-week	native-country	salary
0	39	State-gov	77516	Bachelors	13	Never-married	Adm-clerical	Not-in-family	White	Male	2174	0	40	United-States	<=50K
1	50	Self-emp-not-inc	83311	Bachelors	13	Married-civ-spouse	Exec-managerial	Husband	White	Male	0	0	13	United-States	<=50K
4	28	Private	338409	Bachelors	13	Married-civ-spouse	Prof-specialty	Wife	Black	Female	0	0	40	Cuba	<=50K
5	37	Private	284582	Masters	14	Married-civ-spouse	Exec-managerial	Wife	White	Female	0	0	40	United-States	<=50K
8	31	Private	45781	Masters	14	Never-married	Prof-specialty	Not-in-family	White	Female	14084	0	50	United-States	>50K

Eğer DataFrame'deki her öğenin yukarıdaki listedeki değerleri içermeyenleri görmek istiyorsak ufak bir *not in* (~) işareti ekleyeceğiz.

```
lower_education = data.loc[~data["education"].isin(array_higher_edu)]
lower_education
output:
```

	age	workclass	fnlwgt	education	education-num	marital-status	occupation	relationship	race	sex	capital-gain	capital-loss	hours-per-week	native-country	salary
2	38	Private	215646	HS-grad	9	Divorced	Handlers-cleaners	Not-in-family	White	Male	0	0	40	United-States	<=50K
3	53	Private	234721	11th	7	Married-civ-spouse	Handlers-cleaners	Husband	Black	Male	0	0	40	United-States	<=50K
6	49	Private	160187	9th	5	Married-spouse-absent	Other-service	Not-in-family	Black	Female	0	0	16	Jamaica	<=50K
7	52	Self-emp-not-inc	209642	HS-grad	9	Married-civ-spouse	Exec-managerial	Husband	White	Male	0	0	45	United-States	>50K

Lisans, Yüksek Lisans veya Doktora yapanları ve yapmayanları iki ayrı değişkene atadık. İki grup arasında 50 binden fazla kazananların yüzdesel oranını hesaplayacağız.

Lisans, Yüksek Lisans veya Doktora yapanlar:

```
higher_education_salary50k_count = len(
    higher_education[higher_education['salary'] == '>50K']
)
higher_education_rich = (
    higher_education_salary50k_count/len(higher_education)
) *100
print(higher_education_rich)
output:
46.535843011613935
```

Lisans, Yüksek Lisans veya Doktora yapmayanlar:

```
lower_education_salary50k_count = len(
    lower_education[lower_education['salary'] == '>50K']
)
lower_education_rich = (
    lower_education_salary50k_count/len(lower_education)
) *100
print(lower_education_rich)
output:
17.3713601914639
```

Dataframe'de herhangi bir verinin minimum değerini bulmak için min fonksiyonunu kullanırız. Bir kişinin haftada çalıştığı minimum saat sayısı:

```
min_work_hours = data['hours-per-week'].min()
print(min_work_hours)
output:
1
```

Haftada asgari saat çalışanların ve 50 binden fazla alanları bulmak için yine loc fonksiyonundan yararlanacağız. Haftalık asgari çalışma saatini 45 olarak alabiliriz. İki durumunda True olması için ve operatörünü kullanıyoruz.

```
num_min_workers = data.loc[
    (data['salary'] == ">50K") &
    (data["hours-per-week"]<45)
]

num_min_workers
output:
```

	age	workclass	fnlwgt	education	education-num	marital-status	occupation	relationship	race	sex	capital-gain	capital-loss	hours-per-week	native-country	salary
9	42	Private	159449	Bachelors	13	Married-civ-spouse	Exec-managerial	Husband	White	Male	5178	0	40	United-States	>50K
11	30	State-gov	141297	Bachelors	13	Married-civ-spouse	Prof-specialty	Husband	Asian-Pac-Islander	Male	0	0	40	India	>50K
14	40	Private	121772	Assoc-voc	11	Married-civ-spouse	Craft-repair	Husband	Asian-Pac-Islander	Male	0	0	40	?	>50K
25	56	Local-gov	216851	Bachelors	13	Married-civ-spouse	Tech-support	Husband	White	Male	0	0	40	United-States	>50K
38	31	Private	84154	Some-college	10	Married-civ-spouse	Sales	Husband	White	Male	0	0	38	?	>50K

Bizden bu çalışanların yüzdesi isteniyor.

```
rich_percentage = (
    len(num_min_workers) / len(data['hours-per-week'])
) * 100
print(rich_percentage)
```

Ülkelere göre 50 binden fazla kazanan çalışanların sayısını hesaplamak için value_counts fonksiyonundan yararlanacağız. Hep yaptığımız gibi :) Kategorik verileri sayısını bize döndürüyor.

```
highest_salary_country_count = data.loc[
    data['salary'] == '>50K',
    'native-country'].value_counts()

output:
United-States      7171
?                  146
Philippines        61
.
.
.
Nicaragua           2
Honduras            1
Name: native-country, dtype: int64
```

Ülkelerin sahip olduğu çalışanları yüzdesel olarak hesaplamamız lazım. Toplam ülke sayısını 50 binden fazla alan çalışan sayısına sahip ülkelere böleceğiz. Bizden sadece en yüksek yüzdeye sahip ülke isteniyor. İstenen sütun üzerindeki maximum değerini *idxmax* fonksiyonu döndürür.

```
highest_earning_country = (
    (highest_salary_country_count / country_count) * 100).idxmax()
print(highest_earning_country)

output:
Iran
```

Peki İran'ın yüzdesi nedir?

```
highest_earning_country_percentage = ((highest_salary_country_count /
country_count) * 100).max()
print(highest_earning_country_percentage)

output:
41.86046511627907
```

Son sorumuzda Hindistan'da 50 binden fazla kazandıran en popüler meslek nedir? İlk aşamada Hindistan'da olup 50 binden fazla kazananları bulalım.

```
highest_salary_IN = data[
    (data['salary'] == '>50K') &
    (data['native-country'] == 'India')
]
```

output:

	age	workclass	fnlwgt	education	education-num	marital-status	occupation	relationship	race	sex	capital-gain	capital-loss	hours-per-week	native-country	salary
11	30	State-gov	141297	Bachelors	13	Married-civ-spouse	Prof-specialty	Husband	Asian-Pac-Islander	Male	0	0	40	India	>50K
968	48	Private	164966	Bachelors	13	Married-civ-spouse	Exec-managerial	Husband	Asian-Pac-Islander	Male	0	0	40	India	>50K
1327	52	Private	168381	HS-grad	9	Widowed	Other-service	Unmarried	Asian-Pac-Islander	Female	0	0	40	India	>50K

Şimdi buradaki mesleklerin sayısını bulalım. En yüksek sayıya sahip meslek en popüler meslek olacak

```
top_IN_occupation = highest_salary_IN['occupation'].value_counts()
output:
Prof-specialty      25
Exec-managerial     8
Tech-support        2
Other-service        2
Sales                1
Transport-moving     1
Adm-clerical         1
Name: occupation, dtype: int64
```

Geriye sadece maximum değere erişmek kaldı. Bunun çözümü tabi ki de idxmax :)

```
top_IN_occupation = highest_salary_IN['occupation'].value_counts().idxmax()
print(top_IN_occupation)
Prof-specialty
```

Öğrenme azminiz için çok teşekkür ederim. Bol pratikli günler :)

Github: @burakakbulut